

Klasyfikacja owoców (i warzyw)



Nataniel Jargiło 252888 Bartosz Palmer 260346



Cel projektu

Celem projektu było stworzenie systemu klasyfikacji owoców i warzyw na podstawie ich cech wizualnych.

Wykorzystano:

- klasyczne metody przetwarzania obrazów
- algorytmu uczenia maszynowego

Projekt koncentruje się na ekstrakcji istotnych cech, takich jak kolor, kształt, tekstura i krawędzie, a następnie na wykorzystaniu tych cech do klasyfikacji obrazów przy użyciu algorytmów K-NN oraz SVM.





Opis problemu

Klasyfikacja owoców i warzyw na podstawie ich cech wizualnych stanowi wyzwanie z kilku powodów:

- Owoce i warzywa charakteryzują się zróżnicowaną teksturą, kolorem oraz kształtem, co wymaga precyzyjnej ekstrakcji cech i dostosowania metod analizy.
- Podobieństwo między gatunkami dodatkowo utrudnia ich rozróżnianie.
- Obrazy owoców wykonane są z różnych perspektyw, przez co niektóre z nich mogą nie reprezentować niektórych cech, jak np. kształt.

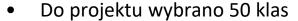
Rozwiązanie tych problemów wymaga opracowania systemu, który potrafi nie tylko skutecznie ekstraktować cechy wizualne, ale również optymalnie wykorzystywać algorytmy klasyfikacyjne w celu uzyskania wysokiej dokładności i niezawodności w przewidywaniu klas obiektów.





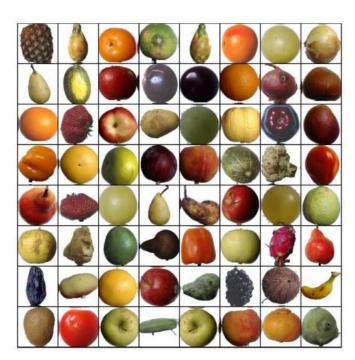
Zbiór danych

- Zbiór danych Fruits 360
- Obrazy 100x100 px
- Zdjęcia z różnych perspektyw
- 141 gatunków owoców i warzyw



- Ok. 90 tysięcy zdjęć na neutralnym tle
- Wyrównano liczbę obrazów dla wszystkich klas
 - Zestaw treningowy: 426 obrazów
 - Zestaw testowy: 142 obrazy







Algorytm - ekstrakcja cech

- Wykorzystanie klasycznych algorytmów przetwarzania obrazów w celu ekstrakcji cech oraz stworzenia z nich wektorów będących wejściem do algorytmów klasyfikacji.
- Histogram RGB Analiza rozkładu intensywności kolorów w kanałach czerwonym, zielonym i niebieskim.
- Histogram HSV Wyznaczenie barwy, nasycenia i jasności, co pozwala na lepsze uchwycenie subtelnych różnic kolorystycznych.
- Ekstrakcja tekstury (GLCM) Wyznaczenie cech takich jak kontrast, jednorodność i korelacja na podstawie macierzy współwystępowania poziomów szarości.
- Detekcja krawędzi (Canny) Wykrywanie granic obiektów z dynamicznym progowaniem opartym na medianie intensywności pikseli.
- Identyfikacja kształtów Klasyfikacja podstawowych kształtów (np. koło, czworokąt) za pomocą na podstawie konturów z algorytmu Canny.

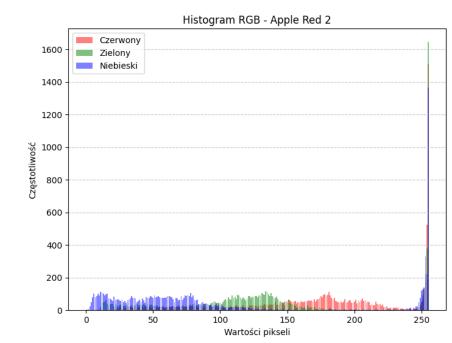




Histogram RGB

Pozwala uchwycić rozkład intensywności kolorów w trzech podstawowych kanałach: czerwonym, zielonym i niebieskim. Analiza ta była szczególnie istotna dla owoców i warzyw o wyraźnych różnicach tonalnych.



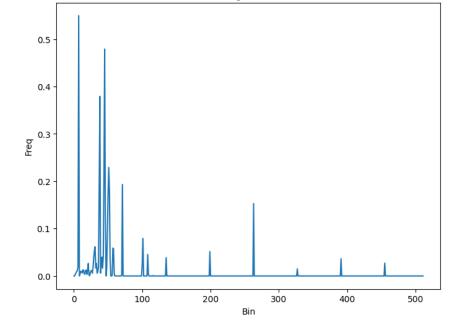




Histogram HSV

Następnie obraz jest konwertowany do przestrzeni barw HSV, a histogram kolorów jest obliczany z podziałem na 8 przedziałów dla każdego z trzech kanałów (H, S, V), co daje histogram o rozmiarze 512 elementów. Zakresy wartości kanałów wynoszą odpowiednio [0, 180] dla H oraz [0, 256] dla S i V. Histogram jest normalizowany i zapisany jako wektor cech Histogram HSV

opisujących rozkład barw w obrazie.



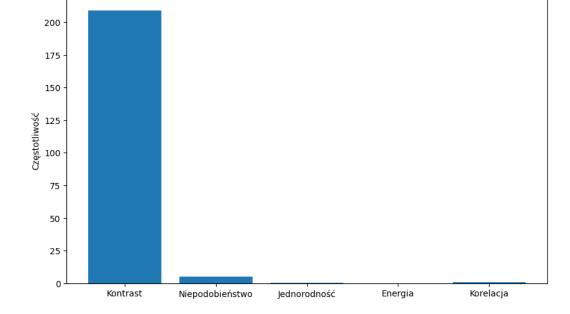




Ekstrakcja cech tekstury - GLCM

Za pomocą macierzy współwystępowania poziomów szarości (GLCM) obliczane są cechy tekstury: kontrast, niepodobieństwo, jednorodność, energia, korelacja oraz średnia energia (ASM). Parametry używane w GLCM obejmują odległość między pikselami wynoszącą 1 oraz kąt analizy równy 0 stopni. Wartości w macierzy są znormalizowane, a liczba poziomów szarości wynosi 256

szarości wynosi 256.



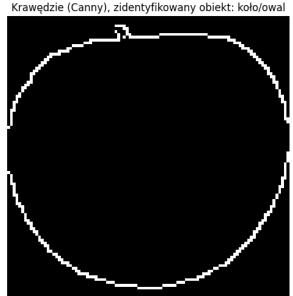




Detekcja krawędzi i identyfikacja kształtu - Canny

- Detekcja krawędzi za pomocą algorytmu Canny
- Dynamiczne obliczanie progów:
 - Obliczenie mediany intensywności pikseli w skali szarości
 - Dolny próg: 2/3 mediany
 - Górny próg: 4/3 mediany
- Na podstawie uzyskanych krawędzi identyfikacja kształtów:
 - trójkat
 - czworokąt
 - koło/owal
 - nieznany kształt





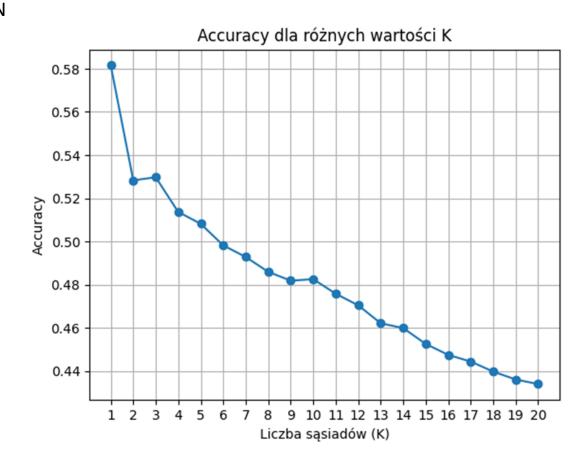


Wrocławska

Klasyfikacja - K-NN

- Optymalizacja K w K-NN
- Odległość Euklidesowa
- K w zakresie [1, 20]
- Optymalne K = 1

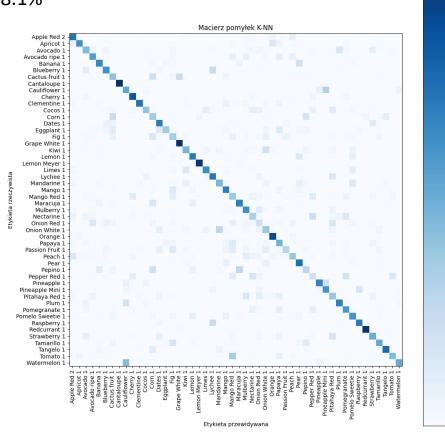






Klasyfikacja - K-NN

Accuracy - 58.1%



120

- 100

40



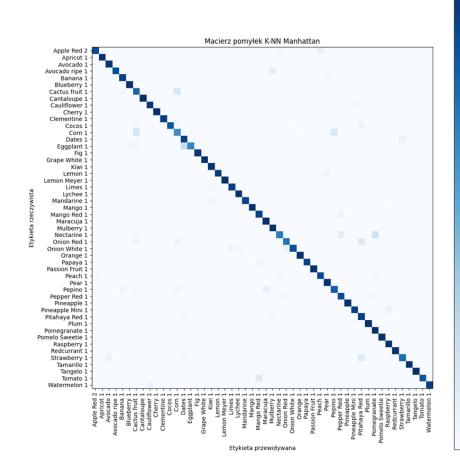


Politechnika Wrocławska

Klasyfikacja - K-NN (Manhattan)

- Odległość Manhattan
- K = 1
- Accuracy 93%



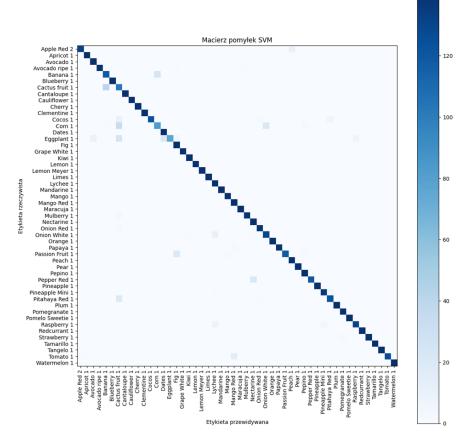




Najlepszy model - SVM

- Liniowe jądro
- Accuracy 95%







SVM - przykładowe błędne klasyfikacje

True: Cactus fruit 1, Predicted: Banana 1











SVM - przykładowe błędne klasyfikacje

True: Avocado ripe 1, Predicted: Fig 1

True: Apple Red 2, Predicted: Peach 1







Podsumowanie

Model	Accuracy	Precision	Recall	F1-score
K-NN (E)	0.581	0.60	0.58	0.58
K-NN (M)	0.927	0.93	0.93	0.93
SVM	0.952	0.96	0.95	0.95





Dziękujemy za uwagę!

