

Projekt

Algorytmy przetwarzania obrazów

Temat: Klasyfikator owoców

Autorzy: Bartosz Palmer 260346

Nataniel Jargiło 252888

1. Wstęp

Celem projektu jest stworzenie systemu klasyfikacji owoców i warzyw na podstawie ich cech wizualnych, wykorzystując klasyczne metody przetwarzania obrazów oraz algorytmy uczenia maszynowego. System opiera się na ekstrakcji cech, takich jak kolor, kształt, tekstura oraz krawędzie, które następnie są wykorzystywane do klasyfikacji obrazów za pomocą klasyfikatorów K-NN oraz SVM.

Ze względu na dużą liczbę klas w zbiorze danych Fruits 360 (ponad 140 klas), wybrano 50 klas, aby zmniejszyć czas przetwarzania oraz ułatwić analizę i optymalizację modeli. Ograniczenie to umożliwiło skupienie się na kluczowych aspektach projektu, takich jak optymalizacja ekstrakcji cech i ewaluacja modelu.

2. Końcowy stan projektu

Od ostatniego etapu realizacji projektu wprowadzono szereg usprawnień i rozszerzeń, które miały na celu zwiększenie dokładności klasyfikatora owoców i warzyw oraz poprawę jakości analiz. Skupiono się na wzbogaceniu ekstrakcji cech, optymalizacji modeli klasyfikacyjnych, a także na wizualizacji i szczegółowej ewaluacji wyników. Dodatkowo, wprowadzono dynamiczne techniki analizy i przetwarzania danych, takie jak wyrównanie liczebności klas w zbiorze treningowym, dynamiczne dostosowywanie progów w metodzie Canny oraz zastosowano bardziej zaawansowane podejścia w ocenie modeli, np. porównanie różnych metryk i algorytmów.

Poniżej przedstawione zostały kluczowe prace zrealizowane od poprzedniego etapu projektu:

2.1. Zbalansowanie zbioru danych

W celu poprawy jakości klasyfikacji oraz uniknięcia problemu związanego z nierównomiernym rozkładem klas, dokonano zbalansowania zbioru danych. Proces ten objął zarówno zbiór treningowy, jak i testowy.


- Analiza liczebności klas:
 - Zbadano liczbę obrazów w każdej klasie zarówno w zbiorze treningowym, jak i testowym.
 - Ustalono najmniejszą liczebność klasy w każdym zbiorze jako wartość referencyjną.
- Zamiana klas z niewystarczającą liczebnością:
 - Cztery klasy o bardzo małej liczbie obrazów zostały zastąpione innymi, bardziej liczebnymi klasami, aby zwiększyć różnorodność i skuteczność klasyfikacji. Były to klasy: Carrot, Cucumber, Mangostan, i Zucchini.
- Przycięcie klas z zbyt dużą liczbą zdjęć:
 - W klasach zawierających więcej obrazów niż najmniejsza liczebność, losowo usunięto nadmiarowe obrazy.
 - Operację tę wykonano osobno dla zbioru treningowego i testowego.

Podczas balansowania zbioru danych, ilość zdjęć została ograniczona w każdej klasie do 426 dla zestawu treningowego oraz 142 dla zestawu testującego.

2.2. Histogram RGB

Dodano histogram RGB, aby uchwycić rozkład intensywności kolorów w kanałach czerwonym (R), zielonym (G) i niebieskim (B). Histogramy zostały obliczone i znormalizowane dla każdego obrazu w zbiorach treningowym i testowym, co umożliwiło lepsze porównywanie danych.

Histogramy RGB wzbogaciły wektory cech, znacząco poprawiając zdolność modelu do rozróżniania klas na podstawie kolorystyki. Dla przykładowego obrazu zaprezentowano histogram RGB, ukazując dominujące barwy i różnice tonalne. Analiza koloru okazała się szczególnie przydatna dla owoców i warzyw o wyraźnych różnicach kolorystycznych, takich jak truskawki, cytryny czy pomarańcze. Na rysunku 1. przedstawiony został przykładowy histogram intensywności RGB (bez normalizacji) dla klasy 'Apple Red 2'.



Rys. 1. Przykładowy histogram intensywności RGB dla klasy Apple Red 2

2.3. Dodanie dynamicznego obliczania progów dla Canny na podstawie median intensywności

W celu poprawy detekcji krawędzi w obrazach zastosowano dynamiczne obliczanie progów dla algorytmu Canny, bazując na medianie intensywności pikseli w odcieniach szarości.

- Dla każdego obrazu obliczono medianę intensywności pikseli po konwersji do skali szarości.
- Na podstawie mediany ustalono dolny próg jako $\frac{2}{3}$ mediany, a górny jako $\frac{4}{3}$ mediany, przycinając wartości do zakresu $[0, 255]$.
- Obliczone progi zostały wykorzystane w funkcji `cv2.Canny` do detekcji krawędzi.


2.4. Identyfikacja podstawowych kształtów (czworokąt, trójkąt, koło/owal, nieznany) na podstawie krawędzi z Canny

W ramach ekstrakcji cech obrazów zaimplementowana została identyfikacja podstawowych kształtów na podstawie krawędzi wykrytych algorytmem Canny. Umożliwiło to klasyfikację obiektów w kategoriach geometrycznych, takich jak trójkąty, czworokąty, koła/owale oraz obiekty o niezidentyfikowanych kształtach.

Działanie algorytmu identyfikacji kształtów:

- Po detekcji krawędzi za pomocą algorytmu Canny z dynamicznie obliczanymi progami, wyodrębniono kontury przy użyciu funkcji `cv2.findContours`.
- Dla każdego konturu obliczono jego obwód i wyznaczono przybliżenie kształtu za pomocą funkcji `cv2.approxPolyDP`, czyli algorytmu Douglasa-Peuckera.
- Aby obliczyć obwód konturu, wykorzystano funkcję `cv2.arcLength`, która zwraca całkowitą długość konturu.
- Obliczona długość obwodu została następnie wykorzystana w funkcji `cv2.approxPolyDP` w celu uproszczenia konturu poprzez redukcję liczb punktów przy zachowaniu jego ogólnego kształtu.
- Wartość parametru epsilon, ustawiona jako $0.04 * \text{obwód}$, co pozwoliło na dynamiczne dostosowanie dokładności uproszczenia w zależności od wielkości konturu.
- Liczba wierzchołków w przybliżonym konturze posłużyła do klasyfikacji:
 - 3 wierzchołki: Trójkąt
 - 4 wierzchołki: Czworokąt
 - Więcej niż 4 wierzchołki: Koło lub owal
 - Inne przypadki: Kształt nieznan
- Uwzględniono tylko największy kontur dla każdego obrazu, co pozwoliło uniknąć analizy drobnych artefaktów.

Na rysunku 2. przedstawiony został wynik działania algorytmu Canny z dynamicznymi progami, wraz z zidentyfikowanym kształtem.




Rys. 2. Przykładowy wynik algorytmu Canny z identyfikacją kształtu

2.5. Znalezienie optymalnego K dla metody K-NN

Przeprowadzono optymalizację liczby sąsiadów (K) dla klasyfikatora K-NN, aby zwiększyć skuteczność modelu. Przetestowano wartości K w zakresie od 1 do 20, wyznaczając dokładność klasyfikacji dla każdej z nich na zbiorze testowym. Wybrano wartość K, która zapewniła najwyższą dokładność modelu. Analizę wyników zaprezentowano na wykresie, pokazującym zależność dokładności od liczby sąsiadów. Optymalizacja K znacząco poprawiła skuteczność klasyfikacji, co pozwoliło lepiej rozpoznawać owoce i warzywa w złożonym zbiorze danych.

Na rysunku 3. przedstawiony został wykres dokładności klasyfikacji K-NN na zestawie testowym w zależności od wartości parametru K.



Rys. 3. Wykres zależności dokładności K-NN od parametru K

2.6. K-NN z odległością Manhattan

W ramach eksperymentów z modelem K-NN wprowadzono metrykę odległości Manhattan, która stanowi alternatywę dla standardowo używanej odległości Euklidesowej. Metryka ta oblicza sumę bezwzględnych różnic między współrzędnymi, co może lepiej odwzorowywać różnice w cechach w niektórych zbiorach danych.

Model K-NN z odległością Manhattan został przetestowany przy użyciu optymalnej liczby sąsiadów K wyznaczonej w poprzednim etapie. Wyniki porównano z modelem K-NN korzystającym z odległości Euklidesowej. Zastosowanie metryki Manhattan pozwoliło na analizę wpływu różnych sposobów mierzenia podobieństwa między wektorami cech na skuteczność klasyfikacji.

2.7. SVM

W projekcie zastosowano również maszynę wektorów nośnych jako alternatywę dla klasyfikatora K-NN. Model SVM, dzięki swojej zdolności do wyznaczania hiperpłaszczyzny maksymalizującej margines między klasami, oferuje inne podejście do klasyfikacji w porównaniu do metody najbliższych sąsiadów.

Dla modelu SVM zastosowano jądro z funkcją liniową, co pozwala na wyznaczenie prostych, liniowych granic decyzyjnych w przestrzeni cech. Model został wytrenowany i przetestowany na tym samym zbiorze danych co K-NN, a jego wyniki zostały porównane pod względem dokładności klasyfikacji, macierzy pomyłek.

2.8. Utworzenie dodatkowych wizualizacji

Od ostatniego etapu projektu wizualizacje zostały rozszerzone o nowe elementy, które obejmowały:

- Histogram RGB – przedstawiono rozkład intensywności kolorów w kanale czerwonym, zielonym i niebieskim dla przykładowego obrazu
- Wyniki identyfikacji kształtu z Canny – zaprezentowano wykryte krawędzie oraz zidentyfikowane kształty geometryczne dla przykładowego obrazu
- Macierz pomyłek dla K-NN z odległością Manhattan oraz dla SVM
- Wyświetlono obrazy błędnie sklasyfikowane przez modele, wraz z rzeczywistymi i przewidywanymi etykietami.

3. Ewaluacja rozwiązań


Ewaluacja systemu klasyfikacji objęła analizę skuteczności modeli K-NN (z odległością Euklidesową i Manhattan) oraz SVM. Oceniono je pod kątem dokładności, analizy macierzy pomyłek, przykładów błędnych klasyfikacji.

3.1. K-NN (odległość Euklidesowa)

Model K-NN z odległością Euklidesową osiągnął ogólną dokładność klasyfikacji na poziomie 58,2%. Analiza wyników wskazuje, że skuteczność klasyfikacji znacząco różni się w zależności od klasy, co jest widoczne w macierzy pomyłek oraz szczegółowym raporcie klasyfikacji.

Kluczowe obserwacje:

- Klasy takie jak Cantaloupe 1 (100% dokładności), Lemon Meyer 1 (97%), czy Redcurrant 1 (96%) osiągnęły bardzo dobre wyniki dzięki ich wyraźnym cechom wizualnym, takim jak specyficzny kolor lub tekstura.
- Klasy o mniej wyraźnych lub podobnych do innych klas cechach, takich jak Pepper Red 1 (22%), Onion Red 1 (20%), czy Mango Red 1 (31%), miały znacznie niższą skuteczność.
- Makro średnia dokładność (0.58) wskazuje na równomierną ocenę modelu w każdej klasie, natomiast ważona średnia (0.60) uwzględnia licznosc klas. Oba wskaźniki są zbliżone, co sugeruje, że model nie preferuje szczególnie żadnej klasy.
- Analiza macierzy pomyłek przedstawionej na rysunku 4. pokazuje, że klasy takie jak Tomato 1, Pepper Red 1, i Onion Red 1 często były mylone z innymi klasami o podobnych kolorach i kształtach.



Rys. 4. Macierz pomyłek K-NN (odległość Euklidesowa)


3.2. K-NN (odległość Manhattan)

Model K-NN z metryką Manhattan osiągnął bardzo wysoką dokładność klasyfikacji na poziomie 92,8%. W porównaniu do odległości Euklidesowej, ten wariant modelu znacząco poprawił wyniki, szczególnie w przypadku klas o wyraźnych różnicach cech.

Kluczowe obserwacje:

- Klasy takie jak Cantaloupe 1, Lemon Meyer 1, Redcurrant 1, Tamarillo 1, i Tangelo 1 osiągnęły 100% dokładności dzięki ich unikalnym cechom wizualnym.
- Dla klas o bardziej złożonych lub podobnych do innych klas cechach, takich jak Avocado ripe 1 (93%) czy Mango Red 1 (87%), także odnotowano istotny wzrost skuteczności w porównaniu do odległości Euklidesowej.
- Znaczące ulepszenia zauważono dla klas takich jak Pepper Red 1 (87%) i Onion Red 1 (80%), które wcześniej były trudne do sklasyfikowania. Wynika to z większej wrażliwości metryki Manhattan na różnice w cechach o różnych skalach.
- Makro i ważone średnie wskaźniki precision, recall i f1-score wyniosły 0.93, co wskazuje na równomiernie wysoką skuteczność dla wszystkich klas, niezależnie od ich liczby i różnorodności.

- Macierz pomyłek przedstawiona na rysunku 5. pokazuje, że liczba błędnych klasyfikacji została znacząco zredukowana. Błędy występują głównie w klasach o podobnych kolorach i kształtach, np. Pepino 1 i Pitahaya Red 1.



Rys. 5. Macierz pomyłek K-NN (odległość Manhattan)


3.3. SVM

Model SVM z jądrem liniowym osiągnął bardzo wysoką dokładność klasyfikacji na poziomie 95,2%. W porównaniu do modeli K-NN, SVM lepiej radził sobie w przypadku złożonych zależności między cechami i zapewnił bardziej spójne wyniki w całym zbiorze danych.

Kluczowe obserwacje:

- Klasy takie jak Cantaloupe 1, Lemon Meyer 1, Tangelo 1, czy Pineapple 1 osiągnęły 100% dokładności, co pokazuje, że model doskonale rozpoznaje obiekty o wyraźnych cechach wizualnych.

- Dla trudniejszych klas, takich jak Cactus fruit 1 (61%) i Corn 1 (67%), model nadal radził sobie lepiej niż K-NN, ale różnice wizualne między klasami mogły wpływać na skuteczność.
- Makro średnia oraz ważona średnia precision, recall i f1-score wyniosły odpowiednio 0.96 i 0.95, co świadczy o równomiernej skuteczności modelu dla wszystkich klas.
- SVM znacząco poprawił wyniki dla klas złożonych, takich jak Pepper Red 1 (92%) i Pitahaya Red 1 (89%), co wskazuje na lepsze zdolności modelu w przypadku bardziej złożonych danych.
- Macierz pomyłek przedstawiona na rysunku 6. wskazuje, że większość błędów dotyczy klas o zbliżonych cechach, takich jak Cactus fruit 1 i Corn 1, gdzie podobieństwa w teksturze i kształcie mogą prowadzić do błędów klasyfikacji.



Rys. 6. Macierz pomyłek SVM

Dodatkowo na rysunkach 7, 8, 9 i 10. przedstawiono przykłady obrazów błędnie sklasyfikowanego przez model SVM.

True: Apple Red 2, Predicted: Peach 1



Rys. 7. Przykład błędnej klasyfikacji SVM (1)

True: Avocado ripe 1, Predicted: Fig 1



Rys. 8. Przykład błędnej klasyfikacji SVM (2)

True: Banana 1, Predicted: Corn 1



Rys. 9. Przykład błędnej klasyfikacji SVM (3)

True: Cactus fruit 1, Predicted: Banana 1



Rys. 10. Przykład błędnej klasyfikacji SVM (4)

3.4. Podsumowanie

W podsumowaniu dokonano porównania trzech modeli klasyfikacyjnych: K-NN z odległością Euklidesową, K-NN z odległością Manhattan oraz SVM. Poniższa tabela 1. przedstawia dokładność, średnie macro dla precision, recall oraz f1-score.

Tabela 1. Porównanie metryk dokładności modeli

Model	Accuracy	Macro avg. precision	Macro avg. recall	Macro avg. F1-score
K-NN (E)	0.581	0.60	0.58	0.58
K-NN (M)	0.927	0.93	0.93	0.93
SVM	0.952	0.96	0.95	0.95

Model bazowy z odległością Euklidesową osiągnął najniższe wyniki spośród wszystkich modeli. Jego skuteczność była ograniczona w przypadku klas o złożonych cechach lub dużym podobieństwie wizualnym.

Zastosowanie odległości Manhattan znacząco poprawiło wyniki klasyfikacji. Model ten lepiej radził sobie w przypadku różnorodnych cech wizualnych, osiągając dokładność na poziomie 92,8%.

SVM z jądrem liniowym okazał się najskuteczniejszym modelem, osiągając najwyższą dokładność (95,2%) oraz najwyższe wartości średnich macro dla precision, recall i f1-score. Model ten wykazał największą zdolność do rozróżniania klas o złożonych zależnościach między cechami.

4. Porównanie z początkową wersją algorytmu

Porównując wyniki najlepszego modelu z obecnego etapu (SVM) z modelem K-NN z poprzedniego etapu projektu, zauważalna jest znacząca poprawa skuteczności klasyfikacji, co można zauważyć w poniżej w tabeli 2.

Tabela 2. Porównanie metryk dokładności SVM z początkowym rozwiązaniem

Model	Accuracy	Macro avg. precision	Macro avg. recall	Macro avg. F1-score
K-NN (poprzedni)	0.586	0.62	0.60	0.59
SVM	0.952	0.96	0.95	0.95

Zastosowanie SVM w obecnym etapie projektu, w połączeniu z ulepszoną reprezentacją cech (histogramy RGB, analiza tekstury, identyfikacja kształtów), pozwoliło osiągnąć znacznie wyższą skuteczność klasyfikacji w porównaniu do modelu K-NN z poprzedniego etapu.

5. Podsumowanie

W ramach projektu opracowano system klasyfikacji owoców i warzyw, wykorzystując klasyczne metody przetwarzania obrazów. Porównano trzy modele: K-NN z odległością Euklidesową i Manhattan oraz SVM z jądrem liniowym. Najlepsze wyniki osiągnięto przy zastosowaniu modelu SVM, który uzyskał dokładność klasyfikacji na poziomie 95,2%, znacząco przewyższając skuteczność modeli K-NN oraz wyniki z poprzedniego etapu projektu.

W finalnym etapie projektu, oprócz wykorzystania innych modeli klasyfikacji wprowadzone zostały również dodatkowe ulepszenia takie jak:

- Zbalansowanie zbioru danych oraz zastąpienie klas z małą liczbą obrazów bardziej liczebnymi
- Rozszerzenie ekstrakcji cech o histogramy RGB, dynamiczne progowanie w algorytmie Canny oraz analizę kształtów
- Optymalizację liczby sąsiadów w modelu K-NN
- Wprowadzenie dodatkowych wizualizacji, które ułatwiły analizę danych i wyników klasyfikacji

Wnioski z projektu wskazują, że klasyczne metody przetwarzania obrazów w połączeniu z dobrze dobranym modelem klasyfikacyjnym mogą być bardzo skutecznym narzędziem w zadaniach rozpoznawania obrazów.

6. Kod i dane

Niestety ze względu na rozmiar zestawu danych (> 100 MB) nie został on umieszczony na eportalu.

Pełen projekt ze zbiorem danych jest dostępny w repozytorium:

<https://github.com/plmrr/fruits-classification>